

Image, Vidéo et recherche d'information

Cours T-ITWM

Par: Ali Wali

(ali.wali@ieee.org)




Plan du cours

- Le fossé sémantique
- Indexation et recherche au niveau signal
- Indexation par concepts
- Systèmes mixtes
- Evaluation – (cas de TRECVID)
- Standards – MPEG-7
- Quelques systèmes existants

Le fossé sémantique

- Le problème du « fossé sémantique »
- Niveau « Signal »
- Niveaux « Signal » et « Sémantique »
- Recherche par le contenu

Le problème du « faussé sémantique »



Niveau « Signal »

○ Signal :

- Variable dans le temps, dans l'espace et/ou dans d'autres dimensions physiques,
- Analogique : phénomène physique (pression d'une onde sonore ou distribution d'intensité lumineuse) ou sa modélisation par un autre (électronique ou chimique par exemple),
- Numérique : même contenu mais "discrétisation" :
 - De la valeur,
 - Du temps,
 - De l'espace,
 - Et/ou autres (fréquence lumineuse par exemple).

Niveau « Signal »

○ Signal, exemples :

- Son (monophonique) : valeurs échantillonnées à 16 kHz sur 16 bits (une dimension temporelle, zéro dimensions spatiales),
- Image fixe (monochrome) : valeurs échantillonnées suivant une grille 2D sur 8 bits (zéro dimensions temporelle, deux dimensions spatiales; la fréquence d'échantillonnage spatiale dépend du capteur),
- Son stéréo, image couleur : multiplication des voies (dimension supplémentaire),
- Vidéo : comme image fixe mais en plus échantillonnée dans le temps (24-30 Hz; une dimension temporelle, deux dimensions spatiales, une dimension chromatique),
- Images 3D (scanners), séquences 3D, ...

Niveaux « Signal » et « Sémantique »

- Sémantique (opposé à signal) :
 - Concepts et relations « abstraits »,
 - Représentation symbolique (aussi du signal),
 - Niveaux d'abstraction successifs du niveau « signal/physique/concret/objectif » au niveau « sémantique/conceptuel/symbolique/abstrait/ subjectif »,
 - « Fossé » (Gap) entre les niveaux signal et sémantique (« rouge » versus « 700-600 nm »),
 - Distinction un peu artificielle,
 - Niveaux intermédiaires difficiles à appréhender,
 - RI au niveau signal, sémantique ou mixte.

Recherche par le contenu :

- Aspects :
 - Signal : tableaux de nombres (bas niveau),
 - Sémantique : concepts ou mots-clés (haut niveau).
- Recherche :
 - Sémantique → sémantique : classique pour les textes,
 - Sémantique → signal : images correspondant à un concept
 - Signal → signal : image contenant un morceau d'image
 - Signal → sémantique : concepts associés à une image
- Approches :
 - Montante : signal → sémantique,
 - Descendante : sémantique → signal,
 - Mixtes

Indexation et recherche au niveau signal

- Représentation et correspondance
- Descripteurs de couleur
- Descripteurs de texture
- Descripteurs de points d'intérêt
- Descripteurs de forme
- Descripteurs de mouvement
- Utilisation de plusieurs types de descripteurs
- Calculs de pertinence
- Interface utilisateur
- bilan

Représentation et correspondance

- Représentation, descripteurs :
 - Couleur,
 - Texture,
 - Points d'intérêts,
 - Forme,
 - Mouvement,
 - ...,
- Mesures de ressemblance associées :
 - Dépendent du contenu du descripteur et du contexte d'application.
- Organisation structurée.
- Problèmes de volume et de rapidité.

Descripteurs de couleur

- Moments,
- Histogrammes,
- Espaces de couleurs,
- Correction “subjectives”.

Moments de couleur

- Une image est caractérisée par 9 moments, 3 moments pour 3 canaux de couleur (par exemple R, V et B). Nous définirons le même canal de couleur au $j^{\text{ième}}$ pixel de l'image en tant que p_{ij} . Les trois moments de couleur peuvent alors être définis comme suit:

MOMENT 1 – Mean :

$$E_i = \sum_N^{j=1} \frac{1}{N} p_{ij}$$

MOMENT 2 - Standard Deviation :

$$\sigma_i = \sqrt{\left(\frac{1}{N} \sum_N^{j=1} (p_{ij} - E_i)^2\right)}$$

MOMENT 3 – Skewness :

$$s_i = \sqrt[3]{\left(\frac{1}{N} \sum_N^{j=1} (p_{ij} - E_i)^3\right)}$$

- « Mean » ou la moyenne en français peut être comprise comme la valeur de couleur moyenne dans l'image.
- « Standard Deviation » ou l'écart-type en français est la racine carrée de la variance de la distribution.
- « Skewness » ou l'asymétrie en français peut être comprise comme une mesure du degré d'asymétrie dans la distribution.
- Avantages : faciles/rapides à calculer, descripteurs très compacts,
- Inconvénients : peu précis et peu sélectifs.

Histogrammes

- Monodimensionnels :
 - Histogramme composante par composante ou histogramme unique si l'image est monochrome,
 - L'espace des valeurs de l'intensité est décomposé en intervalles complémentaires (cases ou « bins »),
 - Pour chaque intervalle, on calcule le pourcentage de pixels de l'image dont intensité s'y trouve,
 - $H[k] = (\sum (I \geq C_k \ \&\& \ I < C_{k+1})) / N$ pour l'intervalle (le « bin ») $[C_k, C_{k+1}[$
 - Le vecteur de ces pourcentages est le descripteur,
 - Trois histogrammes monodimensionnels pour les images en couleur

Histogrammes

- Multidimensionnels :
 - L'espace des valeurs de l'intensité est multidimensionnel (en général de dimension 3),
 - L'espace des valeurs de l'intensité est décomposé en parallélépipèdes complémentaires (« bins »),
 - Pour chaque parallélépipède, on calcule le pourcentage de pixels de l'image dont intensité s'y trouve,
 - Les parallélépipèdes sont eux-mêmes organisés suivant un tableau multidimensionnel de même nombre de dimensions : $H[r][g][b]$.
 - Ce tableau est le descripteur (on peut toujours le voir comme un vecteur si on sérialise les composantes).

Histogrammes

○ Multidimensionnels :

Par exemple, si l'on considère une image RVB classique et que l'on quantifie chaque plan couleur sur 4 bins, l'histogramme résultant aura une dimension $4^3 = 64$. Si l'image est originellement codée sur 24 bits (la valeur de chaque plan est dans l'intervalle $[0 - 255]$), l'histogramme couleur sur 64 bins pourrait être représenté par un « cube » de $4 \times 4 \times 4$.

		Rouge															
		0-63				64-127				128-191				192-255			
		Vert				Vert				Vert				Vert			
		0-63	64-127	128-191	192-255	0-63	64-127	128-191	192-255	0-63	64-127	128-191	192-255	0-63	64-127	128-191	192-255
Bleu	0-63	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x
	64-127	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x
	128-191	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x
	192-255	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x

Chaque couleur représentant l'un des 64 bins quantifiés, et x étant alors le nombre de pixels de l'image correspondant à ce bin. En pratique, ce descripteur est généralement représenté par un vecteur mono dimensionnel à 64 dimensions.

Histogrammes

- Sur l'image complète,
- Par blocs :
 - Un histogramme (mono- ou multidimensionnel par bloc),
 - Le descripteur est la concaténation des histogrammes des différents blocs.
 - Typiquement : blocs de 4 x 4 complémentaires mais des choix non symétriques et non complémentaires sont également possibles : par exemple 2 x 2 + image complète + centre.
- Problème de taille → peu de « bins » par dimension ou beaucoup de « bins » au total

Corrélogrammes

- Les parallélépipèdes/bins sont pris dans le produit cartésien de l'espace des couleurs par lui-même : six composantes $H(r_1, g_1, b_1, r_2, g_2, b_2)$ (ou quatre composantes seulement si on réduit l'espace des couleurs à deux dimensions : $H(u_1, v_1, u_2, v_2)$).
- On prend les valeurs des couleurs suivant une distribution de couples de points dans l'image :
 - A une distance donnée les uns des autres,
 - Et/ou dans une ou plusieurs direction(s) donnée(s),
- Permettent de représenter les relations spatiales relatives entre couleurs,
- Gros volumes de données.

Normalisation

- Objectif : s'affranchir au mieux des variations d'éclairement avant extraction des descripteurs.
- Normalisation de « gain » et d'« offset » : forcer une intensité et une variance moyenne pour la luminance en appliquant une même fonction affine à toutes les composantes de couleur,
- Egalisation d'histogramme : forcer un histogramme aussi plat que possible pour la luminance en appliquant une même fonction continue et croissante à toutes les composantes de couleur,
- Normalisation subjective : forcer une normalisation semblable à celle opérée par le système visuel humain : hautement non linéaire et « globale ».

Fonctions de correspondance pour la couleur

- Vecteurs de moments :
 - Distance euclidienne : recherche d'égalité,
 - Angle entre vecteurs : recherche de similarité robuste aux variations d'éclairement,
- Histogrammes :
 - Distance euclidienne : recherche d'égalité,
 - La robustesse aux variations d'éclairement est obtenue par un prétraitement de normalisation,
 - Histogrammes par blocs : somme des plus petites distances seulement (8 sur 16 typiquement) : permet une recherche portant sur une partie seulement de l'image,
- Corrélogrammes :
 - Distance euclidienne.

Espaces de couleur

- Linéaires :
 - RGB : Rouge, vert, bleu,
 - YUV : Luminance, chrominances (C-rouge, C-bleu),
 - LAB : Luminance, « bleu – jaune », « vert – rouge »
- Non linéaires :
 - TSV : teinte, saturation, valeur ou HSV (Hue, Saturation, Value)

$$t \in [0, 360[$$

$$s, v, r, g, b \in [0, 1]$$

r, g, b désignent respectivement les coordonnées RVB,

t, s, v désignent respectivement les coordonnées TSV.

max la plus grande valeur entre r, g et b ; et min la plus petite.

$$t = \begin{cases} 0, & \text{si } max = min \\ (60^\circ \times \frac{g-b}{max-min} + 360^\circ) \bmod 360^\circ, & \text{si } max = r \\ 60^\circ \times \frac{b-r}{max-min} + 120^\circ, & \text{si } max = g \\ 60^\circ \times \frac{r-g}{max-min} + 240^\circ, & \text{si } max = b \end{cases}$$

$$s = \begin{cases} 0, & \text{si } max = 0 \\ 1 - \frac{min}{max}, & \text{sinon} \end{cases}$$

$$v = max$$

Espaces de couleur (Conversion RGB/YUV RGB/YC_RC_B)

RGB→YUV:

$$Y = R * .299 + G * .587 + B * .114;$$

$$U = -0.169 R + -0.332 G + 0.5 B + 128;$$

$$V = 0.5 R -0.419 G -0.0813 B + 128;$$

RGB→YC_RC_B:

- $Y = 0.299*R + 0.587*G + 0.114*B$

- $Cb = -0.169*R - 0.331*G + 0.500*B$

- $Cr = 0.500*R - 0.419*G - 0.081*B$

Descripteurs de texture

- Calculés sur la luminance seulement (en général),
- Concept un peu flou,
- Composition fréquentielle ou variabilité locale,
- Transformées de Fourier,
- Filtres de Gabor,
- Filtres neuronaux,
- Matrices de cooccurrences,
- Nombreuses combinaisons possibles,
- Vecteur de caractéristiques,
- Fonctions de correspondances adaptées,
- Normalisation possible.

Transformée de Gabor

Filtre de Gabor (circulaire) de direction θ , de longueur d'onde λ et d'étendue σ :

$$g(\sigma, \theta, \lambda, I, i, j) = \frac{1}{2\pi\sigma^2} \sum_{k,l} e^{-\left(\frac{k^2+l^2}{2\sigma^2}\right)} \cdot e^{2\pi i \left(\frac{k \cdot \cos\theta + l \cdot \sin\theta}{\lambda}\right)} \cdot I(i+k, j+l)$$

Énergie de l'image à travers ce filtre :

$$E_g(\sigma, \theta, \lambda, I)^2 = \frac{1}{N} \sum_{i,j} |g(\sigma, \theta, \lambda, I, i, j)|^2$$

Transformée de Gabor

Formulation “séparable” :

$$g(\sigma, \theta, \lambda, I, i, j) = \sum_l \frac{e^{-\left(\frac{l^2}{2\sigma^2}\right)}}{\sqrt{2\pi\sigma}} \cdot e^{2\pi i \left(\frac{l \cdot \sin\theta}{\lambda}\right)} \cdot \left(\sum_k \frac{e^{-\left(\frac{k^2}{2\sigma^2}\right)}}{\sqrt{2\pi\sigma}} \cdot e^{2\pi i \left(\frac{k \cdot \cos\theta}{\lambda}\right)} \cdot I(i+k, j+l) \right)$$

$$h(\sigma, \theta, \lambda, I, i, j) = \sum_k \frac{e^{-\left(\frac{k^2}{2\sigma^2}\right)}}{\sqrt{2\pi\sigma}} \cdot e^{2\pi i \left(\frac{k \cdot \cos\theta}{\lambda}\right)} \cdot I(i+k, j) = H(i, j)$$

$$g(\sigma, \theta, \lambda, I, i, j) = \sum_l \frac{e^{-\left(\frac{l^2}{2\sigma^2}\right)}}{\sqrt{2\pi\sigma}} \cdot e^{2\pi i \left(\frac{l \cdot \sin\theta}{\lambda}\right)} \cdot h(\sigma, \theta, \lambda, I, i, j+l) = G(i, j)$$

Transformée de Gabor

Coefficients de combinaison linéaire :

$$c(k) = \frac{e^{-\left(\frac{k^2}{2\sigma^2}\right)}}{\sqrt{2\pi}\sigma} \cdot \left(\cos\left(\frac{2\pi k \cdot \cos\theta}{\lambda}\right) + \mathbf{i} \cdot \sin\left(\frac{2\pi k \cdot \cos\theta}{\lambda}\right) \right)$$

$$d(l) = \frac{e^{-\left(\frac{l^2}{2\sigma^2}\right)}}{\sqrt{2\pi}\sigma} \cdot \left(\cos\left(\frac{2\pi l \cdot \sin\theta}{\lambda}\right) + \mathbf{i} \cdot \sin\left(\frac{2\pi l \cdot \sin\theta}{\lambda}\right) \right)$$

Transformée de Gabor

Expressions simplifiées :


$$H(i, j) = \sum_k c(k).I(i + k, j)$$

$$G(i, j) = \sum_l d(l).H(i, j + l)$$


$$E^2 = \frac{1}{N} \sum_{i,j} |G(i, j)|^2$$

Transformée de Gabor

Elliptique :



Circulaire :



Transformée de Gabor

- Circulaire :
 - échelle λ , angle θ , écart type σ ,
 - σ multiple de λ , typiquement : $\sigma = 1.25 \lambda$, (« même nombre » de longueur d'ondes quel que soit λ)
- Elliptique :
 - échelle λ , angle θ , écarts types σ_λ et σ_θ ,
 - σ_λ et σ_θ multiples de λ , typiquement : $\sigma_\lambda = 0.8 \lambda$ et $\sigma_\theta = 1.6 \lambda$,
- 2 variables indépendantes :
 - échelle λ : N valeurs (typiquement 4 à 8) sur une échelle logarithmique (rapport typique $\sqrt{2}$ à 2)
 - angle θ : P valeurs (typiquement 8),
- N.P éléments dans le descripteur,

Fonctions de correspondance sur les transformées de Gabor

- Distance euclidienne : recherche d'égalité,
- Angle entre vecteurs : recherche de similarité robuste aux variations d'éclairement,

Descripteurs de points d'intérêt

- Points de « haute courbure » ou « coins »,
- Points géométriques « singuliers » de la surface $I[i][j]$,
- Extraits par divers filtres [Schmid 2000] :
 - Calcul des dérivées spatiales à une échelle donnée,
 - Convolution par des dérivées de gaussienne,
 - Construction d'invariants par une combinaison appropriée de ces diverses dérivées (module du gradient par exemple),
 - Chaque point est sélectionné puis représenté par un ensemble de valeurs de ces invariants,
- L'ensemble des points sélectionnés est organisé topologiquement (relations entre points « voisins »)
- La structure est irrégulière et la taille de la description dépend du contenu de l'image,
- Les descriptions sont volumineuses.

Fonctions de correspondance sur les points d'intérêt

- Fonctions en général très complexes,
- Méthodes dites de relaxation :
 - Choisir un point au hasard dans la description de l'image requête,
 - Comparer le voisinage de ce point à tous les voisinages de tous les points du document candidat,
 - Parmi ceux qui sont proches au sens des relations spatiales et des valeurs des attributs associés, effectuer une recherche complémentaires pour voir si les points voisins sont eux aussi proches entre eux au même sens,
 - Propager la correspondance entre points proches en suivant la topologie des points de l'image requête et de l'image candidate,
 - Trouver la meilleure correspondance globale possible respectant ces topologies et conservant des caractéristiques proches pour les points en correspondance,
 - Evaluer (quantifier) globalement la qualité,

Fonctions de correspondance sur les points d'intérêt

- Méthodes très coûteuses en volume de représentation et temps de calcul de la fonction de correspondance,
- Mais très précises et très sélectives [Dufournaud 2000],
- Permettent de retrouver une image à partir d'un extrait de celle-ci par recherche d'une correspondance partielle,
- Peuvent être rendues robustes aux rotations en choisissant des invariants appropriés
- Peuvent être rendues robustes aux changement d'échelle par des représentations multi-échelle (encore plus coûteux)
- Utilisable sur des bases petites à moyennes seulement (~1000 images).

Fonctions de correspondance sur les points d'intérêt




FIG. 1: *Exemple d'une paire d'images comportant un grand changement d'échelle dû à l'utilisation d'un zoom. Le facteur d'échelle entre les images est de 6. La partie commune est encadrée par un rectangle dans la vue de gauche et représente moins de 17% de l'image.*

Descripteurs de forme

- Extraction de formes par des techniques de traitement d'images : régions homogènes obtenues par croissance itérative ou segmentées par le mouvement (vidéo) par exemple,
- Représentation sous forme vectorielle (séquence de vecteurs produisant une courbe, fermée ou non),
- Représentation par des courbes paramétriques (splines),
- Représentation par décomposition fréquentielle,
- Invariance ou non en rotation et en échelle (choix dans la fonction de correspondance),
- Potentiellement plusieurs formes par image.

Fonction de correspondance sur les formes

- Normalisation en rotation ou en échelle ou non,
- Recherche d'un morceau de courbe dans une autre courbe (méthodes de relaxation encore)
- Recherche d'un alignement « optimal » entre deux représentations vectorielle, • Recherche d'invariants dans les jeux de paramètres des splines (extrema de courbure par exemple),
- Recherche d'une composition fréquentielle similaire
- Mesure quantitative entre deux formes,
- Mesure globale entre images : prise en compte des quelques formes les mieux mises en correspondance seulement.

Descripteurs de mouvement

- Pour la vidéo seulement,
- Extraction du mouvement de chaque pixel ou de la correspondance entre pixels d'images consécutives,
- Statistiques sur ces mouvements :
 - Mouvement moyen global : rotation, translation, zoom, ...
 - Intensité moyenne et variance du mouvement,
 - Distribution : histogramme ou texture du champ de vecteurs,
 - Segmentation du fond et des objets mobiles : nombre, taille et vitesse des objets mobiles (ou évaluation de la possibilité de les discerner),
- Mouvements de caméra,
- Structure du fond (mosaïque, scène 3D),
- Description des objets (couleur, forme, texture).

Fonctions de correspondance pour le mouvement

- Statistiques semblables,
- Mouvements de caméra semblables,
- Fonds semblables (couleur, forme, texture),
- Objets mobiles semblables (couleur, forme, texture),
- Distances euclidienne, éventuellement après normalisation,
- Fonction de correspondance habituellement associées aux attributs utilisés pour le fond et les objets segmentés,
- Correspondance globale construite à partir des diverses correspondance entre éléments.

Utilisation de plusieurs types de descripteurs

- Plusieurs types de descripteurs différents : choix en fonction de l'application visée ou du type de requête souhaité,
- Plusieurs fonctions de correspondances différentes pour chaque type de descripteur : choix en fonction de l'application visée ou du type de requête souhaité (invariances voulues ou non par exemple),
- Combinaison des descriptions (fusion précoce),
- Combinaison des fonctions de correspondance (fusion tardive),
- Combinaison avec des descriptions de niveau sémantique.

Fusion des représentations (précoce)

- Cas des descripteurs vectoriels (de taille fixe), quelle que soit leur origine,
- Possibilité de concaténer les différents descripteurs en un descripteur mixte unique → problème de normalisation,
- Possibilité de réduire la dimension du vecteur résultant (ou de chaque vecteur original) pour ne garder que l'information la plus pertinente :
 - Analyse en composantes principales,
 - Réseaux de neurones (« autoencoder »),
 - Nécessité d'un apprentissage (base de données représentative et processus).
- Moins d'information, rapide une fois l'apprentissage fait,
- Distance euclidienne sur le vecteur compacté.

Fusion des fonctions de correspondance (tardive)

- Chaque fonction de correspondance donne en général une valeur quantitative de l'estimation de ressemblance,
- On peut toujours se ramener au cas où les valeurs sont comprises entre 0 et 1 et représentent une pertinence,
- Pour fusionner les résultats de plusieurs fonctions, on peut choisir :
 - Une moyenne pondérée,
 - Un produit pondéré (moyenne pondérée sur les logarithmes),
 - Le minimum des valeurs,
 - Un classifieur (SVM, réseau de neurones, ...)
- Problème du choix des pondération et/ou de l'apprentissage du classifieur.

Calculs de pertinence

- Distance euclidienne, angle entre vecteurs,
- Comparaison d'un vecteurs à tous les vecteurs de la base (pas de présélection),
- « Petit » nombre de dimensions (< 10) : techniques de regroupement et recherche hiérarchique,
- Nombre « moyen » ($\sim 10+$) : méthodes de partitionnement de l'espace,
- Nombre « élevé » ($>> 10$) : pas de méthode connue plus efficace que le parcours complet,
- Réduction du nombre de dimensions par ACP.

Interface utilisateur

- Interface classique pour la partie de la requête effectuée au niveau sémantique,
- Plus la possibilité de définir une requête au niveau signal :
 - Requête par l'exemple : une ou plusieurs images, images initiales ou sélectionnées par "bouclage de pertinence",
 - Bibliothèque d'éléments signal : couleurs, textures, formes (pouvant être entrées sous forme de croquis),
 - Moyen de définir une importance relative pour les diverses caractéristiques signal (ou sémantiques) disponibles,
 - Moyen de définir une méthode pour la fusion des fonctions de correspondances (moyenne, produit, min, ...),
 - Le système peut aussi faire ces choix par analyse du bouclage de pertinence,
 - Lien entre le signal et la sémantique.

Calculs dans le domaine compressé

- Avantages : « simplicité », rapidité, « efficacité »,
- Inconvénients :
 - Dépendant du format,
 - Moins précis,
 - Dissymétries,
 - Contraintes artificielles,
 - Les éléments compressés ne sont pas optimisés pour cela et ne sont donc pas idéalement adaptés,
 - Techniques « ad hoc »,
 - Pas possible pour tous les descripteurs, seulement pour : couleur, texture, mouvement.

Couleur dans le domaine compressé

- Formats JPEG, MPEG ou semblables (basés sur une DCT par blocs),
- Extraction des seuls coefficients DC (composante continue), 1 valeur par bloc 8 x 8 (ou 16 x 16),
- Statistiques :
 - moments d'ordre 1 ou 2,
 - moments mixtes avec les composantes spatiales,
 - histogrammes (sur des images de taille suffisante).

Texture dans le domaine compressé

- Formats JPEG, MPEG ou semblables (basés sur une DCT par blocs),
- Analyse fréquentielle :
 - Utilisation des coefficients AC (composante fréquentielle) pour les hautes fréquence : regroupement des énergies par groupes de coefficients associés à des orientations et des longueurs d'onde données,
 - Utilisation de l'image DC (composante continue) pour les fréquence moyennes et basses : calcul classique par FFT ou filtres de Gabor simplifiés.

Mouvement dans le domaine compressé

- Formats MPEG ou semblables (utilisant une prédiction par compensation de mouvement),
- Récupération des vecteurs de prédiction de mouvement :
 - Données incomplètes et dissymétriques,
 - Problème de la fiabilité des vecteurs,
- Utilisable pour des statistiques (mouvement faible, fort, irrégulier, ...) et une estimation grossière (gauche, droite, haut, bas, zoom, ...),
- Peu fiable pour retrouver un mouvement fin de la caméra ou construire de bonnes représentations du fond et des objets mobiles.

Recherche au niveau signal : bilan

- Représentation par différents types de descripteurs et mesure de pertinence par diverses fonctions,
- Un type unique : résultats mauvais à moyens,
- Plusieurs types simultanément : résultats moyens à bons, avec adaptation au domaine possible,
- Possibilité de régler le compromis qualité – performance – généralité – taille de la base,
- Performances limitées par le côté « analogique » (non symbolique) des représentations.

Indexation par concepts

- Segmentation de la vidéo
- Segmentation en objets et mouvement de caméra
- Modèles de mouvement caméra / fond
- Du signal vers la sémantique
- Indexation par concepts

Segmentation de la vidéo

- Segmentation de la piste image
 - Segmentation en plans,
 - Segmentation et poursuite des objets mobiles,
 - Mouvement de caméra et des objets mobiles,
 - Extraction d'images-clés
- Segmentation de la piste audio
 - Silence / musique / bruit / parole / ...
 - Homme / femme
 - Haute qualité / téléphone / ...
 - Locuteurs / Locuteurs connus
- Sous-plan (micro-)segmentation
- Histoire / sujet (macro-)segmentation


Segmentation en objets et mouvement de caméra

- Segmentation classique d'image en objets (par la couleur, la texture, les régions, les contours, ...) plus :
- Extraction des objets mobiles relativement à un fond et mouvement relatif entre la caméra et le fond :
 - Les objets sont repérés comme ne suivant pas le mouvement du fond
 - Le mouvement du fond est retrouvé par l'application d'un modèle (paramétrique) de mouvement sur la partie de l'image ne contenant pas d'objets mobiles
 - La dépendance réciproque peut être contournée par l'utilisation de méthodes itératives si le fond occupe une proportion suffisamment importante de l'image
 - Plusieurs modèles de mouvement doivent être considérés
 - Compromis à trouver entre la vitesse de traitement et la qualité du résultat (vecteurs MPEG versus calcul complet du flot optique)
- Combinaison de segmentation d'image (fixe) et de segmentation par le mouvement
- Images « mosaïques » ou vues 3D du fond

Segmentation temporelle macro-découpage et micro-découpage

- **Prise de vue ou plan (shot):** Une prise de vue est une série d'images acquises par une seule caméra d'un seul tenant et n'ayant donné lieu à aucun montage. Cet ensemble d'images représente une action continue dans le temps et dans l'espace.
- **Scène (scene):** Une scène est constituée d'un ensemble de prises de vue ayant une même unité de lieu (divers points de vue par exemple).
- **Séquence ou segment (sequence):** Une séquence regroupe diverses prises de vue et scènes ayant une même unité de sujet (par exemple un reportage).
- **Macro-découpage temporel:** Par macro découpage temporelle on entend la partie du découpage temporel d'un fichier vidéo ne descendant pas au-dessous de la prise de vue, qui est alors, pour cette étape, l'entité atomique.
- **Micro-découpage temporel:** Le micro-découpage temporel consiste en un découpage temporel des prises de vue d'un document vidéo en sous unités allant jusqu'à l'entité atomique constituée par l'image clé.


Segmentation temporelle macro-découpage et micro-découpage



Segmentation spatiale de la vidéo

- La logique de la structuration linéaire entreprise dans ce niveau se poursuit par un découpage cette fois-ci spatial des images clés ou images caractéristiques retenues pour chaque entité issue du découpage temporel.
- Ce découpage spatial n'est autre qu'une segmentation d'images ceci près que les régions extraites doivent également posséder un contenu sémantique propre.
- On cherche à obtenir une segmentation en objets.
 - Ainsi pour une scène représentant un personnage assis dans l'herbe sous un arbre les trois objets principaux extraire sont le personnage l'arbre et la zone d'herbe.
 - Bien sûr, d'autres segmentations plus fines aboutissant par exemple à un découpage du personnage en plusieurs régions (sa tête et son corps etc...) sont également acceptables dans un contexte d'indexation: chaque objet a son propre contenu sémantique.

Segmentation spatiale de la vidéo



Représentation de la hiérarchie Document Vidéo Séquence Scène et Prise de vue

- La structure de document vidéo contient une série d'informations relatives à la notion de fichier vidéo, aux données brutes constituées par les images.
- La partie structure du document vidéo est conçue simplement sous la forme de quelques informations telles que numéros des images de départ et de fin du document vidéo nombre de séquences pointeur sur la liste des séquences.
- Chaque séquence est elle-même de la même forme, à ceci près qu'elle contient un nombre de scènes et un pointeur vers la liste chronologique de ces scènes.
- Enfin chaque scène est décomposée de la même façon à partir de prises de vue.

DocData
Largeur_Image
Hauteur_Image
Nombre_Images
Fréquence_Acquisition
Format_Image


DocStruc
Numéro_Image_Début
Numéro_Image_Fin
Nombre_Séquences
Liste_Séquences

Séquence
Numéro_Image_Début
Numéro_Image_Fin
Nombre_Scènes
Liste_Scènes

Scène
Numéro_Image_Début
Numéro_Image_Fin
Nombre_PprisesDeVue
Liste_PprisesDeVue



Représentation de la hiérarchie Document Vidéo Séquence Scène et Prise de vue

Au final on obtient donc la représentation UML (Unified Modeling Language) présentée dans la figure suivante:




Modèles de mouvement caméra / fond 7 degrés de liberté (descripteurs MPEG7)

- Modèle de caméra paramétrique, 7 paramètres:
- Translation: « track », « boom or pedestal », « dolly »,
- Rotation: « tilt », « pan », « roll »,
- Zoom ou focale



Exemple d'estimation de mouvement



Application de l'estimation de mouvement: suivie d'objet mobile

